

Relatório Final – Desafio 13

Classificação multiclasse de manchetes de notícias com técnicas de NLP e aprendizado de máquina

Versão revisada — pipeline aprimorado e análise de erros

Disciplina	Machine Learning – Teoria e Aplicado	Data de entrega	04/06/2026
Grupo	13	Dataset	News Category Dataset (Kaggle)
Professora	Ma. Nathália A. Lima	Tipo	Classificação multiclasse

Integrantes e RAs

Nome do integrante	RA
Miguel Guarnetti de Moraes	1999154
Gabriel Fante Javarotti	1990554
Leonardo Lopes Martins Silva	2010503

Objetivo do trabalho

O projeto teve como objetivo classificar automaticamente manchetes de notícias em categorias temáticas, apoiando a organização de conteúdo e a recomendação personalizada em plataformas jornalísticas. Para reduzir a complexidade do problema, o estudo foi concentrado nas cinco categorias mais frequentes do conjunto de dados.

Recorte analítico utilizado

Categoria	Qtd. de notícias	Participação no recorte
POLITICS	35.602	39,3%
WELLNESS	17.945	19,8%
ENTERTAINMENT	17.362	19,2%
TRAVEL	9.900	10,9%
STYLE & BEAUTY	9.814	10,8%

A base original continha 209.527 registros e 42 categorias. Após o filtro das cinco classes mais frequentes, o conjunto de trabalho passou a ter 90.623 manchetes.

1. Análise exploratória dos dados

A etapa de EDA confirmou que o recorte é desbalanceado, com forte predominância de POLITICS. Também foram observadas diferenças no comprimento médio das manchetes: ENTERTAINMENT, POLITICS e STYLE & BEAUTY tendem a usar títulos mais longos, enquanto TRAVEL e WELLNESS apresentam manchetes mais curtas.




Figura 1 - Distribuição das cinco categorias mais frequentes no recorte utilizado.




Figura 2 - Comprimento médio das manchetes por categoria, em número de palavras e dispersão.

Os valores médios de palavras por manchete foram: ENTERTAINMENT 10,7; STYLE & BEAUTY 10,4; POLITICS 10,3; TRAVEL 8,3; e WELLNESS 8,1. Esses padrões ajudam a entender a heterogeneidade textual que o modelo precisou aprender durante o treinamento.

2. Pré-processamento e comparação de modelos

Etapa		Síntese aplicada no notebook
Limpeza textual		lowercase, remoção de pontuação e normalização de espaços.
Tratamento de inconsistências		remoção de manchetes duplicadas e de manchetes que ficaram vazias após a limpeza.
Vetorização		TF-IDF com ngram_range=(1,2), stop words em inglês, min_df=2 e max_features=50.000.

Etapa	Síntese aplicada no notebook
Divisão dos dados	Treino/validação/teste em 60/20/20 com estratificação por classe.
Modelos	MultinomialNB, LogisticRegression e LinearSVC.
Validação	Stratified K-Fold com k=3 e métricas macro (acurácia, precisão, recall e F1).
Seleção do modelo	melhor F1-Score Macro na validação ; o teste é usado apenas para reporte final.

Resultados da validação cruzada (k=3)

Modelo	Acurácia	Precisão Macro	Recall Macro	F1-Score Macro
MultinomialNB	0,8634	0,8580	0,8344	0,8453
LogisticRegression	0,8718	0,8718	0,8437	0,8561
LinearSVC	0,8754	0,8707	0,8523	0,8607

Resultados finais no conjunto de teste

Modelo	Acurácia	Precisão Macro	Recall Macro	F1-Score Macro
MultinomialNB	0,8669	0,8626	0,8354	0,8479
LogisticRegression	0,8806	0,8753	0,8569	0,8653
LinearSVC	0,8838	0,8760	0,8633	0,8692




Figura 3 - Comparação visual das métricas médias na validação cruzada entre os três classificadores.

Os resultados mostram consistência entre validação cruzada e teste final. LinearSVC obteve o melhor desempenho global, seguido de LogisticRegression; MultinomialNB ficou abaixo dos modelos lineares em todas as métricas macro.

3. Diferenças técnicas aplicadas nesta versão NOVO

Em relação à versão anterior do notebook, foram introduzidos ajustes técnicos voltados à robustez metodológica e à profundidade da análise. O quadro abaixo resume cada mudança e o motivo técnico por trás dela.

Mudança	Motivação técnica
Remoção de duplicatas antes da divisão	manchetes repetidas que caíssem simultaneamente em treino e teste configurariam data leakage , inflando artificialmente as métricas. A deduplicação ocorre antes de qualquer split.
Remoção de manchetes vazias após a limpeza	títulos compostos apenas por números/símbolos geram vetores TF-IDF nulos, que não contribuem para o aprendizado.
Seleção do modelo pela validação	a escolha do melhor classificador passou a usar o conjunto de validação , mantendo o teste intocado e exclusivo para o reporte final — prática correta para evitar viés de seleção.
Remoção do parâmetro <code>multi_class</code>	o argumento estava depreciado no scikit-learn (≥ 1.5); com o solver lbfgs, o comportamento multinomial já é o padrão.
Métricas por classe corrigidas	as métricas por categoria foram recalculadas diretamente da matriz de confusão, garantindo o mapeamento correto entre rótulo e desempenho.
Seção dedicada de análise de erros	nova etapa que investiga onde e por que o modelo erra, indo além das métricas agregadas (ver Seção 4).

4. Análise de erros NOVO

Esta seção foca no comportamento de erro do melhor modelo (LinearSVC) no conjunto de teste. Das 18.125 manchetes avaliadas, 2.106 foram classificadas incorretamente (taxa de erro global de 11,6%). A análise a seguir mostra como esses erros se distribuem entre as categorias e quais pares de classes concentram a maior parte das confusões.




Figura 4 - Quantidade absoluta de erros e taxa de erro por categoria (LinearSVC).

Em números absolutos, ENTERTAINMENT concentra mais erros (528), mas, quando normalizamos pelo tamanho da classe, **TRAVEL é a categoria mais difícil** (18,9% de taxa de erro), seguida de STYLE & BEAUTY (15,4%) e ENTERTAINMENT (15,2%). POLITICS, apesar de ser a maior classe, é a mais fácil de classificar (apenas 6,4% de erro), por possuir vocabulário muito característico.




Figura 5 - Mapa de calor das confusões entre classes, com a diagonal (acertos) zerada.




Figura 6 - Pares de classes mais confundidos pelo modelo.

Os pares mais confundidos são ENTERTAINMENT → POLITICS (245), POLITICS → WELLNESS (207), WELLNESS → POLITICS (194), POLITICS → ENTERTAINMENT (164) e TRAVEL → WELLNESS (160). Dois padrões se destacam: (i) por ser a maior classe, POLITICS funciona como um “atrator” de manchetes ambíguas; e (ii) TRAVEL e WELLNESS compartilham vocabulário de estilo de vida, o que explica a confusão recorrente entre elas.

Complemento no notebook. Além dos gráficos acima, a seção de análise de erros do notebook examina a **confiança do modelo** (margem da função de decisão) em acertos versus erros — mostrando que os erros se concentram em predições de baixa confiança — e o **tamanho das manchetes** mal classificadas, além de listar exemplos concretos dos “erros mais confiantes” para inspeção qualitativa.

5. Síntese dos resultados e conclusão

Melhor modelo: LinearSVC

Acurácia de 88,38% e F1-Score Macro de 86,92% no conjunto de teste. Esse resultado indica o melhor equilíbrio entre precisão e recall nas cinco categorias avaliadas.

Desempenho por categoria (LinearSVC)

Categoria	Precisão	Recall	F1-Score	Suporte
POLITICS	0,9197	0,9361	0,9278	7.121
STYLE & BEAUTY	0,8954	0,8462	0,8701	1.963
ENTERTAINMENT	0,8679	0,8479	0,8578	3.472
WELLNESS	0,8332	0,8755	0,8538	3.589
TRAVEL	0,8639	0,8111	0,8367	1.980



Figura 7 - Nuvem de palavras mais frequentes por categoria no recorte selecionado.




Figura 8 - Matriz de confusão do melhor modelo (LinearSVC), em contagens absolutas e proporções por linha.

A matriz de confusão mostra que a classe mais bem separada foi POLITICS (94% de recall), enquanto TRAVEL foi a mais difícil (81%), com parte de suas manchetes confundida com WELLNESS. Parte relevante

dos erros também ocorre entre POLITICS e ENTERTAINMENT, classes que compartilham termos sobre figuras públicas e mídia.

Em síntese, o notebook atende ao objetivo proposto pela atividade e demonstra que a combinação de limpeza textual, representação TF-IDF com bigramas e modelos lineares é eficaz para classificação multiclasse de manchetes de notícias. A versão revisada acrescentou tratamento de inconsistências (deduplicação), seleção de modelo metodologicamente correta (via validação) e uma análise de erros aprofundada, tornando os resultados mais confiáveis e interpretáveis. A escolha final pelo LinearSVC foi coerente com as métricas obtidas e com a análise qualitativa dos erros. Como evolução futura, recomenda-se ampliar o recorte para mais categorias e testar representações contextuais (embeddings) para reduzir as confusões entre classes tematicamente próximas.